


IDEA LAB AI STUDY

PCA & MLE 추가 조사

익명1

(지도교수: 양선웅)

한양대학교 ERICA 기계공학과



IDEA

Intelligent Design
for Engineering
Applications Lab

PCA : Principal Component Analysis

- PCA는 고차원 데이터에서 정보가 가장 많이 담긴 방향을 찾아 그 방향으로 데이터를 투영하는 차원 축소 방법
- 투영은 어떤 벡터를 특정 방향이나 평면 위로 내리는 것 [Figure 2]

PCA 기본 개념


❖ PCA 원리

- ✓ 정보가 많이 담긴 방향 = **분산이 큰 방향**
- ✓ 데이터가 가장 많이 퍼져 있는 방향 탐색 [Figure 1]
- ✓ 데이터가 가장 많이 퍼져 있는 방향은 어디인가?
 - 제 1 주성분, 제 2 주성분, ...
- ✓ 중요 조건 : 주성분은 서로 직교
- ✓ 분산이 큰 방향을 선택하는 이유
 - : 투영했을 때 데이터 간의 차이가 잘 보존되기 때문


❖ PCA 의 장단점

- ✓ 장점
 - 고차원 데이터를 저차원으로
 - 시각화 용이하고 노이즈 줄일 수 있음
- ✓ 단점
 - 곡선 구조 데이터의 표현이 어려움
 - 분류에서 사용하기는 어려운 구조

Figure



[Figure 1]



[Figure 2]

PCA의 Mathematical Method

- PCA는 정보가 가장 많이 남는 방향으로 차원 축소
- 투영 값 z 들의 분산이 가장 커지는 방향 w 를 찾음

PCA의 흐름

❖ 데이터의 차원

- ✓ 하나의 데이터는 행렬로써 표현되며 n 차원의 데이터는 $n \times 1$ 의 행렬로써 나타낼 수 있음

❖ PCA 과정

1. 데이터 행렬 제작 (n 개 데이터, d 개의 변수, $d \times n$ 행렬)
2. 평균 중심화
3. Covariance Matrix 계산
4. 투영된 데이터의 분산 계산
5. PCA의 최적화
6. Eigenvalue 문제 풀이
7. 상위 k 개의 주성분 선택

원리 설명

❖ Variance

- ✓ $Var(X) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$

❖ 평균 중심화

- ✓ $\tilde{X} = X - \mu$
- ✓ 각 데이터의 평균이 0에 위치하도록 수정

❖ Covariance Matrix 계산

- ✓ $S = \frac{1}{n-1} \tilde{X}^T \tilde{X}$

❖ 투영된 데이터의 variance 계산

- ✓ 투영 값 : $z_i = w^T \tilde{x}_i$
- ✓ 투영된 데이터의 분산 : $Var(z) = w^T S w$
- ✓ $\max_w w^T S w$ 찾기

❖ 분산이 가장 큰 방향 단위벡터 w 찾기

- ✓ $S w = \lambda w$
- ✓ λ 찾은 후 큰 순서대로 정렬, 가장 큰 λ 의 w 가 제 1 주성분

❖ 설명 분산비

- ✓ $\frac{\lambda_1}{\lambda_1 + \lambda_2 + \dots + \lambda_d}$

❖ 기존 데이터를 주성분 방향으로 투영

- ✓ $Z = \tilde{X} W$

MLE

- MLE는 이미 관측한 데이터 중 가장 그럴듯하게 나오게 만들 수 있는 **모델 파라미터를 찾는 것**
- 확률은 파라미터가 고정되고, 데이터가 변하지만 우도는 데이터의 관측이 먼저이고 파라미터를 변수로 설정

MLE의 수학적 정의

❖ 데이터 D가 행렬로 존재

- ✓ 데이터의 출처가 어떠한 확률 모델 $p(x|\theta)$ 임
- ✓ 여기서 θ 는 찾고 싶은 모델 파라미터
- ✓ 모델마다 파라미터가 다름
 - 동전 던지기 : 앞면 확률 p
 - 정규 분포 : 평균, 분산
 - 선형회귀 : 가중치 w , 절편 b
 - 로지스틱 회귀 : 가중치 벡터 w
 - 신경망 : 모든 weight, bias

✓ 데이터가 독립 일 경우

전체 데이터가 나올 확률은 곱으로 표현

$$p(D|\theta) = p(x_1, x_2, \dots, x_n|\theta)$$

여기서 기인한 것이 **우도 함수**, 이를 **최대로 만드는 파라미터**를 찾는 것

$$L(\theta) = \prod_{i=1}^n p(x_i|\theta)$$

MLE와 Loss Function

- ❖ MLE는 정답이 나올 확률을 크게 만들
- ❖ Loss function은 손실을 줄이는 방향으로 학습
- ❖ MLE와 Loss function은 밀접한 관계가 있음

MLE로 통하는 손실함수 — 문제 유형별 정리

모든 손실함수는 결국 '정답이 나올 확률(우도)'을 가장 크게 만드는 같은 원리다

문제 유형	모델이 예측하는 것	MLE 관점	손실함수
회귀	숫자값	실제값이 예측값 근처에서 나올 확률을 높임	MSE
이진분류	0/1 확률	정답 라벨의 확률을 높임	BCE
다중분류	여러 클래스 확률	정답 클래스의 확률을 높임	Cross Entropy
언어모델	다음 단어 확률	실제 다음 단어의 확률을 높임	Cross Entropy

MLE와 Loss function


- MLE는 모델의 학습에 있어서 정답 데이터가 나올 확률을 높이는 방향으로 학습
- MLE는 **확률 극대화** 원리, Loss function은 이를 **최소화 문제**로 변환한 것

선형 회귀와 MSE

- ❖ 머신 러닝 학습에서는 우도를 직접 최대화하기 보다는, 로그를 취한 **로그 우도를 사용하여 계산을 단순화**
- ❖ Loss function은 모델의 예측이 실제 값과 얼마나 다른지를 나타내며, 학습 과정에서는 이 값을 최소화 함
- ❖ 따라서 머신 러닝 모델 학습은 통계적으로 볼 때, **우도 최대화를 손실함수 최소화 문제로 바꾼 과정**이라고 할 수 있음

최대우도법(MLE) — AI는 어떻게 '가장 그럴듯한' 직선을 찾을까

AI의 질문: "이 직선이 참이라면, 지금 본 데이터가 나올 확률은?" → 그 확률이 가장 큰 직선을 고른다



왜 둘이 같은가? — 오차가 정규분포이기 때문

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \prod_i \mathcal{N}(y_i | \hat{y}_i, \sigma^2) \iff \arg \min_{\theta} \sum_i (y_i - \hat{y}_i)^2$$

곱을 로그로 퍼면 합이 되고, 정규분포의 지수부가 바로 $-(y_i - \hat{y}_i)^2 \rightarrow$ 우도 최대화 = 제곱오차 최소화

MLE는 AI에서 Loss function과 관계가 존재

- MLE는 확률 모델을 정한 후 우도 함수 $L(\theta)$ 를 만들고 이를 미분해서 최댓값 조건을 찾아냄
- 도출된 파라미터는 데이터의 확률이 됨

MLE의 계산 순서

❖ 예제 1 : 베르누이 분포일 경우에서 MLE

- ✓ 베르누이 분포에서 확률 질량 함수 $P(X_i = x_i | p) = p^{x_i}(1 - p)^{1-x_i}$
- ✓ 위의 식에서 $x_i = 1$ 일 때 p , $x_i = 0$ 일 때 $1 - p$
- ✓ 우도 함수는 $L(\theta) = \prod_{i=1}^n p^{x_i}(1 - p)^{1-x_i}$ 이며 정리하면 아래와 같이 확률 p 로써 정리가 가능함
- ✓ $L(p) = p^k(1 - p)^{n-k}$
- ✓ 로그를 씌운 후 로그 성질을 이용함
- ✓ $l(p) = k \log p + (n - k) \log(1 - p)$ 이를 p 에 대해 최대화 하는 것 즉, 이를 미분함
- ✓ MLE의 조건은 미분한 값이 0이 되는 것
- ✓ 정리하면 $\hat{p}_{MLE} = \frac{k}{n}$ 이는 전체 시행 횟수 중 성공 횟수와 같음

베르누이 분포 MLE와 BCE loss function

- ❖ 모델이 예측한 확률이 $\hat{p}$ 일 때 정답 y 가 나올 확률
 - ✓ $P(y) = \hat{p}^y(1 - \hat{p})^{1-y}$
- ❖ MLE는 정답 데이터 확률을 크게 만들고 싶어 함
 - ✓ $P(y) = \hat{p}^y(1 - \hat{p})^{1-y}$ 에 $\log$ 를 씌우고 최대화 함
- ❖ 손실함수를 최소화 하는 방식
 - ✓ $BCE = -[y \log \hat{p} + (1 - y) \log(1 - \hat{p})]$
- ❖ 따라서 우도에서 $\log$ 를 씌우고 음수를 붙이면 BCE 손실함수
 - ✓ BCE 최소화 = 베르누이 우도 최대화

MLE와 Loss function

- MLE는 모델의 학습에 있어서 정답 데이터가 나올 확률을 높이는 방향으로 학습
- 각 모델의 MLE를 적용하는 중 우도 최대화에 영향을 주는 항을 Loss function으로 선정

평균과 분산의 MLE

❖ 예제 2 : 정규 분포의 경우

- ✓ 정규 분포에서 데이터가 나왔다면 확률 밀도 함수는 다음과 같음

- ✓ $p(x_i | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$

- ✓ 파라미터는 $\theta = (\mu, \sigma^2)$

- ✓ 우도 함수에 로그를 씌워 정리하면 다음과 같음

- ✓ $l(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$

- ✓ 핵심은 마지막 항에서 평균과 데이터의 차를 제곱

- 따라서 정규 분포 가정 아래에서 MLE는 최소제곱법과 연결

선형 회귀와 MSE

❖ 선형 회귀

- ✓ $y_i = \mathbf{w}^T \mathbf{x}_i + b + \varepsilon_i$

- ✓ 오차 ε_i 가 정규 분포를 따른다고 가정

- ✓ 모델의 예측 값 : $\hat{y}_i = \mathbf{w}^T \mathbf{x}_i + b$

- ✓ 정규 분포의 로그 우도는 다음 항을 포함하며 이를 최대화 하는 것은 MSE와 같음

- ✓ 실제 값 y_i 가 예측 값 $\hat{y}_i$ 를 평균으로 하는 정규 분포 출신이라 가정

- ✓ $\sum_{i=1}^n (y_i - \hat{y}_i)^2$

MLE와 Loss function

- MLE는 모델의 학습에 있어서 정답 데이터가 나올 확률을 높이는 방향으로 학습
- 각 모델의 MLE를 적용하는 중 우도 최대화에 영향을 주는 항을 Loss function으로 선정


선형 회귀와 MSE

❖ 정규 분포에서 로그 우도 함수

- ✓ $\log L = \text{const} - \frac{1}{2\sigma^2} \sum_{i=1} (y_i - \hat{y}_i)^2$
- ✓ 따라서 로그 우도 함수를 크게 만드는 것은 최소 제곱법과 같음
- ✓ AI에서 회귀 문제를 풀 때 자주 쓰는 MSE
- ✓ MLE와 MSE의 차이는 전체 합 $\sum_{i=1} (y_i - \hat{y}_i)^2$ 을 n 으로 나누는 것
- ✓ n 으로 나누는 이유 : batch size에 구애 받지 않고 gradient 계산
- ✓ 만약 오차가 라플라스 분포를 따른다면 MAE가 나오게 됨

최대우도법(MLE) — AI는 어떻게 '가장 그럴듯한' 직선을 찾을까

AI의 질문: “이 직선이 참이라면, 지금 본 데이터가 나올 확률은?” → 그 확률이 가장 큰 직선을 고른다



왜 둘이 같은가? — 오차가 정규분포이기 때문

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \prod_i \mathcal{N}(y_i | \hat{y}_i, \sigma^2) \iff \arg \min_{\theta} \sum_i (y_i - \hat{y}_i)^2$$

곱을 로그로 퍼면 합이 되고, 정규분포의 지수부가 바로 $-(y_i - \hat{y}_i)^2$ → 우도 최대화 = 제곱오차 최소화

Any Questions?

이름 익명1

소속 한양대학교 기계공학과

이메일 jshan0407@hanyang.ac.kr



*Intelligent Design
for Engineering
Applications Lab*

