


IDEA LAB AI STUDY

PCA & MLE 추가 조사

익명2

(지도교수: 양선웅)

한양대학교 ERICA 기계공학과



IDEA

Intelligent Design
for Engineering
Applications Lab

PCA(Principal Component Analysis)


- 대표적인 Dimensionality reduction에 쓰이는 기법으로 머신러닝, 데이터마이닝, 노이즈 제거 등 다양한 분야에서 사용
- PCA를 이용하면 고차원의 데이터를 낮은 차원의 데이터로 변경해줄 수 있다는 것인데 중요한 것은 “어떻게 차원을 잘 낮추느냐”

Why?

❖ 데이터를 어떻게 대표할 수 있을까?


학생들의 수학, 과학 점수가 있을 때, 학생들의 종합 실력을 한 개의 점수로 표현하고 싶으면 보통 평균을 떠올림. 하지만 수학 시험이 더 어려웠거나 과학이 더 중요한 과목이라면 평균이 최적이지 아닐 수도 있음.

→ “가장 데이터를 잘 설명하는 종합점수”를 만드는 것 = PCA



- ❖ 잘 바꾼다고 하더라도 2차원의 모든 데이터 특징을 포함하여 1차원 데이터로 변경하기는 어려움
- ❖ 최대한 특징을 살리면서 차원을 낮춰주는 방법 → PCA

How?








Mathematical Elements

- Variance, Covariance, Covariance Matrix, Eigenvector, Eigenvalue, ...


Elements

- Variance (데이터가 얼마나 넓게 퍼져있는지)
- Covariance(고차원에서 데이터들 간의 분산)






$$\text{Cov}(x,y) = \frac{\sum (x - \bar{x})(y - \bar{y})}{n}$$

- Covariance Matrix







Matrix 1: $\begin{bmatrix} 3 & 2 \\ 2 & 4 \end{bmatrix}$, Matrix 2: $\begin{bmatrix} 3 & -2 \\ -2 & 4 \end{bmatrix}$, Matrix 3: $\begin{bmatrix} 5 & 0 \\ 0 & 1 \end{bmatrix}$





$$\Sigma = \begin{pmatrix} \text{Var}(X) & \text{Cov}(X,Y) \\ \text{Cov}(X,Y) & \text{Var}(Y) \end{pmatrix}$$

- Eigenvector, Eigenvalue



선형변환
 $(x,y) \rightarrow (8x+3y, 3x+2y)$



$$A\vec{x} = \lambda\vec{x}$$

Mathematical Interpretation

❖ Covariance Matrix

$$X = \begin{pmatrix} | & | & | & \cdots & | \\ X_1 & X_2 & X_3 & \cdots & X_d \\ | & | & | & \cdots & | \end{pmatrix} \in \mathbb{R}^{n \times d}$$

$$D = \begin{bmatrix} 170 & 70 \\ 150 & 45 \\ 160 & 55 \\ 180 & 60 \\ 170 & 80 \end{bmatrix} \quad X = D - \text{mean}(D) = \begin{bmatrix} 170 & 70 \\ 150 & 45 \\ 160 & 55 \\ 180 & 60 \\ 172 & 80 \end{bmatrix} - \begin{bmatrix} 166 & 62 \\ 166 & 62 \\ 166 & 62 \\ 166 & 62 \\ 166 & 62 \end{bmatrix} = \begin{bmatrix} 4 & 8 \\ -16 & -17 \\ -6 & -7 \\ 14 & -2 \\ 6 & 18 \end{bmatrix}$$

$$X^T X = \begin{pmatrix} \text{---} X_1 \text{---} \\ \text{---} X_2 \text{---} \\ \vdots \\ \text{---} X_d \text{---} \end{pmatrix} \begin{pmatrix} | & | & | & \cdots & | \\ X_1 & X_2 & X_3 & \cdots & X_d \\ | & | & | & \cdots & | \end{pmatrix}$$

$$= \begin{pmatrix} \text{dot}(X_1, X_1) & \text{dot}(X_1, X_2) & \cdots & \text{dot}(X_1, X_d) \\ \text{dot}(X_2, X_1) & \text{dot}(X_2, X_2) & \cdots & \text{dot}(X_2, X_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{dot}(X_d, X_1) & \text{dot}(X_d, X_2) & \cdots & \text{dot}(X_d, X_d) \end{pmatrix}$$

$$X^T X = \begin{bmatrix} 4 & -16 & -6 & 14 & 6 \\ 8 & -17 & -7 & -2 & 18 \end{bmatrix} \begin{bmatrix} 4 & 8 \\ -16 & -17 \\ -6 & -7 \\ 14 & -2 \\ 6 & 18 \end{bmatrix} = \begin{bmatrix} 540 & 426 \\ 426 & 730 \end{bmatrix}$$

$$\Sigma = \frac{1}{n} X^T X$$

$$\text{Cov}(x, y) = \frac{\sum (x - \bar{x})(y - \bar{y})}{n} \quad \Sigma = \frac{1}{n} X^T X$$

모집단(Population)

$$\text{Cov}(X, Y) = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$$

표본(Sample)

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum (x_i - \bar{x})(y_i - \bar{y})$$

❖ Calculation Process

원본 데이터 → 평균 제거(Mean Centering) → 데이터 행렬 X 생성

→ Feature끼리 비교하기 위해 Transpose → $X^T X$ 계산

→ 분산과 공분산이 모두 들어있는 공분산 행렬 생성

→ 공분산 행렬의 고유벡터 / 고윳값 계산



→ 가장 큰 고윳값의 고유벡터 = PC1 → 데이터를 PC1으로 정사영

→ 차원 축소 완료

MLE(Maximum Likelihood Estimation)

- 확률 밀도 함수에서 관측된 표본 데이터를 바탕으로 확률분포의 미지의 모수(Parameter)를 추정하는 통계적 방법
- 관측된 실제 데이터가 추출될 가능성(우도, Likelihood)을 가장 높게 만드는 최적의 모수를 찾는 것이 목표

$$x = \{1, 4, 5, 6, 9\}$$




Element

❖ Likelihood(우도)

❖ Parameter(모수)

데이터 확률분포 → 모수 → 확률 → 우도 → 로그우도 → MLE



Mathematical Interpretation

- ❖ Likelihood function/Log-likelihood function

$$P(x|\theta) = \prod_{k=1}^n P(x_k|\theta)$$

$$L(\theta|x) = \log P(x|\theta) = \sum_{i=1}^n \log P(x_i|\theta)$$

$$\frac{\partial}{\partial \theta} L(\theta|x) = \frac{\partial}{\partial \theta} \log P(x|\theta) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log P(x_i|\theta) = 0$$

- ❖ Likelihood function Maximum value

$$\frac{\partial}{\partial \theta} L(\theta|x) = \frac{\partial}{\partial \theta} \log P(x|\theta) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log P(x_i|\theta) = 0$$

Any Questions?

이름 익명2
소속 한양대학교 기계공학과
이메일 broha@hanyang.ac.kr



*Intelligent Design
for Engineering
Applications Lab*

